

Diagnóstico de sobreajuste y subajuste

Reporte técnico · Actividad de la semana 3

Proyecto: Predicción de matrícula y continuidad estudiantil, Unidad Educativa LEMAS

Guillermo Granizo y José Ulloa · Maestría en Inteligencia Artificial, UEES · 2 de octubre de 2026

Versión preliminar con datos sintéticos. Las cifras de este documento prueban el método y no describen a LEMAS. La versión final se genera con los datos reales seudonimizados.

1. Resumen ejecutivo

Qué se hizo. Se diagnosticó si los tres modelos de la Fase 2 (regresión logística regularizada, gradient boosting y logística híbrida) memorizan los datos de entrenamiento o no aprenden lo suficiente. Para ello se registraron las métricas durante el entrenamiento, se generaron cuatro tipos de curvas de aprendizaje, se cuantificó el ajuste con dos reglas prácticas y se evaluaron 6 estrategias de mejora con comparación antes y después. Se entrenó con C1+C2+C3 y se validó con C4; la cohorte de prueba (C5) no intervino.

Qué se encontró.

- **Regresión logística, gradient boosting y logística híbrida** presentan **ajuste adecuado**.
- Los dos modelos de control, que son casos extremos, se clasifican como se esperaba (sobreajuste y subajuste). Esto comprueba la regla en casos claros, no en los casos cercanos a los umbrales.
- De las 6 estrategias evaluadas, la PR-AUC en C4 mejora en 2, empeora en 3 y no cambia de forma apreciable en 0; E2 no modificó el modelo en esta ejecución.
- La de mayor efecto es **E6 · Más entrenamiento**: de 0,149 a 0,166 (Lift@k de 1,40 a 1,57).
- En E3, E4, E5 y E6 el modelo de partida no presentaba el problema que la estrategia busca corregir: esos resultados son comprobaciones, no correcciones.
- Reducen la brecha 1 de las 3 estrategias contra el sobreajuste.
- Cambian el diagnóstico: E1 (sobreajuste → ajuste adecuado); E3 (ajuste adecuado → subajuste).
- Al pasar de la mitad al total del entrenamiento, el cambio de la PR-AUC de validación es menor que dos veces la variación entre submuestras en los tres modelos: con estos datos no se puede afirmar que más datos ayuden ni que no ayuden.

Qué significa para el proyecto. Este análisis no cambia la decisión final, que es priorizar el contacto con la regla D2. Las diferencias observadas en C4 son indicios y no pruebas: C4 ya se usó para seleccionar y calibrar en la Fase 2, y solo tiene 100 eventos. Para confirmar una mejora hace falta una cohorte que no haya participado en ninguna decisión.

Entregables. Cuaderno *overfitting_analysis.ipynb*, módulos *src/diagnostico.py* y *src/graficos_diagnostico.py* con pruebas automáticas, cinco figuras a 300 DPI y este reporte.

2. Metodología utilizada

2.1 Datos y particiones

Cada fila es un estudiante con reserva aprobada al 20 de febrero; el evento es no pagar la matrícula hasta el 30 de abril. Las particiones respetan el orden temporal: se entrena con cohortes anteriores y se valida con la siguiente. No se usan particiones al azar entre años, porque filtrarían información del futuro.

Partición	Entrena con	Valida con	N entr.	Eventos entr.	N val.	Eventos val.	Uso
Diagnóstico	C1+C2+C3	C4	3401	291	1134	100	Curvas, diagnóstico y medición de las estrategias
Interna	C1+C2	C3	2242	206	1159	85	Elegir sin mirar C4 (parada temprana)

Puntaje y pérdida. La actividad pide una curva de exactitud o de puntaje. La tasa de eventos en C4 es 8,8 %: con clases tan desbalanceadas la exactitud no informa, porque un modelo que nunca detecta un caso acierta en casi todos. Por eso el puntaje es la **PR-AUC** (precisión promedio), donde un ordenamiento al azar obtiene la tasa de eventos. La **pérdida** es la entropía cruzada; en los modelos entrenados con clases balanceadas se pondera igual que durante el entrenamiento, así que la pérdida solo se compara entre curvas del mismo modelo.

2.2 Seguimiento de métricas

Los modelos son de scikit-learn. El seguimiento está en *src/diagnostico.py* y guarda cada medición en un mismo registro (*RegistroMetricas*: una fila por modelo, paso y conjunto):

- **Gradient boosting, por iteración.** *seguir_boosting* mide la pérdida y la PR-AUC de entrenamiento y de validación después de cada árbol añadido.
- **Regresiones logísticas, por iteración del optimizador.** scikit-learn no expone su estado intermedio, así que *seguir_logistica* entrena con un límite de iteraciones creciente hasta que el optimizador converge; el último punto es el modelo final.
- **learning_curve** de scikit-learn, para el efecto del tamaño del entrenamiento (5 submuestras por tamaño).
- **validation_curve** de scikit-learn, para el efecto de un hiperparámetro con el resto fijo.

2.3 Modelos analizados

Los modelos base son los tres de la Fase 2, con los hiperparámetros que eligió Optuna, leídos del historial guardado. Al reentrenarlos, su PR-AUC en la validación coincide con la tabla de la Fase 2 (diferencia máxima 0,0000). Se añaden dos modelos de control, definidos de antemano, que no son candidatos: un gradient boosting sin regularizar, que debe sobreajustar, y una regresión logística con penalización L1 extrema, que debe subajustar.

2.4 Reglas de diagnóstico

Diagnóstico	Patrón en las curvas	Regla cuantitativa
Sobreajuste	La brecha crece; el entrenamiento mejora y la validación se estanca o empeora	Brecha relativa de PR-AUC mayor que 30 %
Subajuste	Las dos curvas quedan juntas en un nivel pobre	Sin esa brecha, PR-AUC de validación menor que 1,5 veces el azar
Ajuste adecuado	Brecha pequeña y estable en un nivel útil	Ninguna de las dos condiciones anteriores

Brecha relativa = (entrenamiento – validación) / entrenamiento. En las curvas durante el entrenamiento se mide además el paso con menor pérdida de validación y cuánto sube la pérdida después (deterioro, si supera 0,01). Una estrategia «mejora» o «empeora» solo si la PR-AUC cambia al menos 0,005.

Alcance de estas reglas. Son reglas prácticas, no pruebas estadísticas. Los umbrales están en *config.yaml* y se fijaron el 2 de octubre de 2026, antes de ejecutar este análisis con datos reales, pero cuando ya se conocían las PR-AUC de entrenamiento y de C4 de la Fase 2. La brecha compara dos conjuntos cuya tasa de eventos puede ser distinta, por eso la Tabla 1 muestra también cuántas veces supera al azar cada conjunto. La tabla de ajuste de la Fase 2 usó una regla más simple (brecha absoluta mayor que 0,10; entrenamiento menor que 0,15), que puede diferir de esta en casos límite.

3. Resultados del diagnóstico

Modelo	Rol	PR-AUC entr.	PR-AUC C4	Brecha	Brecha relativa	Veces el azar (entr.)	Veces el azar (C4)	Diagnóstico
Regresión logística	Fase 2	0,162	0,166	−0,004	−3 %	1,89	1,88	ajuste adecuado
Gradient boosting	Fase 2	0,168	0,149	+0,019	11 %	1,96	1,69	ajuste adecuado
Logística híbrida	Fase 2	0,133	0,143	−0,011	−8 %	1,55	1,62	ajuste adecuado
Control: árboles sin regularizar	control	0,994	0,141	+0,853	86 %	11,62	1,60	sobreajuste
Control: logística sobrerregularizada	control	0,086	0,088	−0,003	−3 %	1,00	1,00	subajuste

Tabla 1. Diagnóstico por modelo (C1+C2+C3 → C4).

- **Regresión logística, gradient boosting y logística híbrida** presentan **ajuste adecuado**.
- Los dos modelos de control, que son casos extremos, se clasifican como se esperaba (sobreajuste y subajuste). Esto comprueba la regla en casos claros, no en los casos cercanos a los umbrales.

4. Análisis de curvas de aprendizaje

Todas las figuras se generan a 300 DPI. Azul es entrenamiento y rosa con marcadores redondos es validación. En las regresiones logísticas cada punto es un entrenamiento completo con ese límite de iteraciones.

4.1 Curva A: pérdida durante el entrenamiento

A. Pérdida de entrenamiento y de validación durante el entrenamiento

Entrenamiento: C1+C2+C3 · Validación: C4 · C5 no interviene · cada panel tiene su propia escala




Figura 1. Pérdida de entrenamiento y de validación en cada paso. Cada panel tiene su propia escala.

- Gradient boosting (Fase 2): la pérdida de validación es mínima en el paso 139 de 400 (0,680). Después cambia solo +0,002: la validación se estanca, no se deteriora. La Fase 2 usó 72 iteraciones (pérdida de validación 0,681).
- Control: árboles sin regularizar: la pérdida de validación es mínima en el paso 5 de 300 (0,686). Después sube 0,869 mientras el entrenamiento sigue bajando: es el patrón de sobreajuste.
- Regresión logística (Fase 2): la pérdida de validación es mínima en el paso 3 de 14 (0,292). Después cambia solo +0,001: la validación se estanca, no se deteriora.
- Logística híbrida (Fase 2): la pérdida de validación es mínima en el paso 4 de 8 (0,296). Después cambia solo +0,001: la validación se estanca, no se deteriora.

4.2 Curva B: PR-AUC durante el entrenamiento

B. PR-AUC de entrenamiento y de validación durante el entrenamiento

Entrenamiento: C1+C2+C3 · Validación: C4 · C5 no interviene · cada panel tiene su propia escala




Figura 2. PR-AUC de entrenamiento y de validación en cada paso.

- **Gradient boosting (Fase 2):** la PR-AUC de validación es máxima en el paso 377 (0,173). Al final (paso 400), la brecha de PR-AUC es +0,031 y la de pérdida 0,046, mayor que en el punto óptimo.
- **Control: árboles sin regularizar:** la PR-AUC de validación es máxima en el paso 17 (0,172). Al final (paso 300), la brecha de PR-AUC es +0,853 y la de pérdida 1,458, mayor que en el punto óptimo.
- **Regresión logística (Fase 2):** la PR-AUC de validación es máxima en el paso 3 (0,167). Al final (paso 14), la brecha de PR-AUC es -0,004 y la de pérdida 0,011.
- **Logística híbrida (Fase 2):** la PR-AUC de validación es máxima en el paso 8 (0,143). Al final (paso 8), la brecha de PR-AUC es -0,011 y la de pérdida 0,007.

4.3 Curva C: tamaño del entrenamiento (opcional)

C. Curvas de aprendizaje según el tamaño del entrenamiento

Submuestras de C1+C2+C3 · Validación fija: C4 · banda = ± 1 desviación entre submuestras




Figura 3. PR-AUC según el número de estudiantes en el entrenamiento. La banda es ± 1 desviación entre submuestras.

- **Regresión logística:** la validación pasa de 0,153 con 1768 estudiantes a 0,166 con 3401 ($+0,013$; variación entre submuestras $\pm 0,014$). La diferencia no llega al doble de esa variación: no es concluyente.
- **Gradient boosting:** la validación pasa de 0,143 con 1768 estudiantes a 0,149 con 3401 ($+0,006$; variación entre submuestras $\pm 0,022$). La diferencia no llega al doble de esa variación: no es concluyente.
- **Logística híbrida:** la validación pasa de 0,139 con 1768 estudiantes a 0,143 con 3401 ($+0,004$; variación entre submuestras $\pm 0,003$). La diferencia no llega al doble de esa variación: no es concluyente.

4.4 Curva D: hiperparámetros (opcional)

D. Curvas de validación: efecto de un hiperparámetro

Entrenamiento: C1+C2+C3 · Validación: C4 · los demás hiperparámetros, como en la Fase 2




Figura 4. PR-AUC al variar un hiperparámetro; la línea discontinua marca el valor de la Fase 2.

- **Regresión logística,** al variar C: la validación es máxima en 0,0316 (0,167); la Fase 2 eligió 0,0242. En el valor más alto (10), el entrenamiento llega a 0,164 y la validación queda en 0,162.
- **Gradient boosting,** al variar la tasa de aprendizaje: la validación es máxima en 0,0891 (0,171); la Fase 2 eligió 0,0158. En el valor más alto (0,501), el entrenamiento llega a 0,281 y la validación queda en 0,161.
- **Logística híbrida,** al variar C: la validación es máxima en 0,0316 (0,151); la Fase 2 eligió 0,00139. En el valor más alto (10), el entrenamiento llega a 0,157 y la validación queda en 0,143.

5. Estrategias implementadas y resultados

Se implementaron 6 estrategias (la actividad pide al menos dos), todas medidas en la misma partición. Cada una aplica un solo tipo de cambio (E3 ajusta a la vez los hiperparámetros de complejidad), con dos excepciones: E1 parte de un modelo de control y no de un candidato, y E4 cambia las variables y también los hiperparámetros. La parada temprana elige sus iteraciones por menor pérdida en la validación interna (C1+C2 → C3) y solo puede recortar el entrenamiento.

Estrategia y cambio aplicado	PR-AUC C4	Brecha	Lift@k	Diagnóstico
E1 · Regularización y menor complejidad (contra el sobreajuste) búsqueda con Optuna (Fase 2): tasa de aprendizaje 0,1 → 0,0158; profundidad sin límite → 2; mínimo de muestras por hoja 5 → 59; L2 0 → 1,94	0,141 → 0,149 mejora	+0,853 → +0,019 se reduce	1,51 → 1,40	sobreajuste → ajuste adecuado
E2 · Parada temprana (contra el sobreajuste) no recorta: en la validación interna la pérdida sigue bajando hasta la iteración 72	0,149 → 0,149 el modelo no cambia	+0,019 → +0,019	1,40 → 1,40	ajuste adecuado
E3 · Modelo más simple (contra el sobreajuste) hojas 7 → 4; mínimo de muestras por hoja 59 → 100; L2 1,94 → 10; mismas iteraciones	0,149 → 0,130 empeora	+0,019 → +0,030 aumenta	1,40 → 1,40	ajuste adecuado → subajuste
E4 · Ingeniería de variables (contra el subajuste) logística híbrida con las señales de D2 (pago tardío, reserva extraordinaria, atrasos por tramos); usa sus propios hiperparámetros de la Fase 2	0,166 → 0,143 empeora	−0,004 → −0,011 aumenta	1,34 → 1,51	ajuste adecuado
E5 · Menos regularización (contra el subajuste) C: 0,0242 → 0,242	0,166 → 0,160 empeora	−0,004 → +0,004 sin cambio apreciable	1,34 → 1,46	ajuste adecuado
E6 · Más entrenamiento (contra el subajuste) iteraciones: 72 → 144	0,149 → 0,166 mejora	+0,019 → +0,014 se reduce	1,40 → 1,57	ajuste adecuado

Tabla 2. Antes → después de cada estrategia. Las palabras «mejora» y «empeora» se refieren a la PR-AUC; el efecto sobre la brecha se juzga por su tamaño (valor absoluto).

Estrategias de mejora: antes y después

Cada flecha va del modelo de partida al modelo con la estrategia · C5 no interviene




Figura 5. Efecto de cada estrategia sobre la PR-AUC de validación, la brecha y el Lift@k por familia.

- De las 6 estrategias evaluadas, la PR-AUC en C4 mejora en 2, empeora en 3 y no cambia de forma apreciable en 0; E2 no modificó el modelo en esta ejecución.
- La de mayor efecto es **E6 · Más entrenamiento**: de 0,149 a 0,166 (Lift@k de 1,40 a 1,57).
- En E3, E4, E5 y E6 el modelo de partida no presentaba el problema que la estrategia busca corregir: esos resultados son comprobaciones, no correcciones.
- Reducen la brecha 1 de las 3 estrategias contra el sobreajuste.
- Cambian el diagnóstico: E1 (sobreajuste → ajuste adecuado); E3 (ajuste adecuado → subajuste).

6. Conclusiones y recomendaciones futuras

Conclusiones

- Modelos de la Fase 2 por diagnóstico: 3 con ajuste adecuado.
- Efecto de las 6 estrategias sobre la PR-AUC en C4: mejora en 2, empeora en 3 y no cambia de forma apreciable en 0; E2 no modificó el modelo.
- Estrategias contra el sobreajuste que reducen la brecha: 1 de 3.
- Este análisis usa solo las cohortes de entrenamiento y C4. C5 ya se evaluó una vez y no interviene, así que estas estrategias no cambian la decisión final del proyecto (priorizar con la regla D2).
- Una brecha pequeña no basta para dar por bueno un modelo: también debe superar al azar con margen. Medir las dos cosas evita confundir estabilidad con utilidad.
- Reducir la brecha y mejorar la validación son efectos distintos. La Tabla 2 los muestra por separado para cada estrategia.

Limitaciones

- Las estrategias se compararon en C4, que ya se usó para seleccionar y calibrar en la Fase 2. Una diferencia pequeña puede ser ruido.

- Hay 100 eventos en la validación: las diferencias de pocas milésimas de PR-AUC no son concluyentes.
- La validación usa una sola cohorte. Las tasas cambian entre ciclos, así que el resultado puede no repetirse el año siguiente.
- Los umbrales de diagnóstico son reglas prácticas y se fijaron conociendo ya los resultados de la Fase 2.

Recomendaciones

- Repetir este diagnóstico cada mayo, cuando se conozca el resultado del ciclo, y evaluar en esa cohorte nueva las estrategias que aquí mejoraron la validación.
- Si se vuelve a entrenar un gradient boosting, elegir el número de iteraciones en la validación interna y comprobar la curva de pérdida antes de aceptarlo.
- Probar información nueva, por ejemplo una señal temprana de intención de la familia, y medir con estas mismas curvas si eleva la validación.
- Conservar la regla D2 para priorizar mientras ningún modelo la supere en una cohorte que no haya participado en las decisiones.

7. Referencias técnicas

- [1] F. Pedregosa *et al.*, «Scikit-learn: Machine Learning in Python», *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.
- [2] scikit-learn developers, «Validation curves: plotting scores to evaluate models», Guía de usuario de scikit-learn. https://scikit-learn.org/stable/modules/learning_curve.html
- [3] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2.ª ed. Nueva York: Springer, 2009, cap. 7.
- [4] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016, caps. 5 y 7.
- [5] L. Prechelt, «Early Stopping — But When?», en *Neural Networks: Tricks of the Trade*, LNCS 1524. Berlín: Springer, 1998, pp. 55-69.
- [6] J. H. Friedman, «Greedy function approximation: A gradient boosting machine», *The Annals of Statistics*, vol. 29, n.º 5, pp. 1189-1232, 2001.
- [7] H. Zou y T. Hastie, «Regularization and variable selection via the elastic net», *Journal of the Royal Statistical Society: Series B*, vol. 67, n.º 2, pp. 301-320, 2005.
- [8] T. Akiba, S. Sano, T. Yanase, T. Ohta y M. Koyama, «Optuna: A Next-generation Hyperparameter Optimization Framework», en *Proc. 25th ACM SIGKDD*, 2019, pp. 2623-2631.
- [9] T. Saito y M. Rehmsmeier, «The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets», *PLoS ONE*, vol. 10, n.º 3, e0118432, 2015.

Código y resultados: github.com/ggranizo2507/prediccion-matricula-lemas
(*notebooks/overfitting_analysis.ipynb*, *src/diagnostico.py*, *results/*).