Diagnóstico de sobreajuste y subajuste

Reporte técnico · Actividad de la semana 3
Proyecto: Predicción de matrícula y continuidad estudiantil, Unidad Educativa LEMAS
Guillermo Granizo y José Ulloa · Maestría en Inteligencia Artificial, UEES · 18 de octubre de 2026

1. Resumen ejecutivo

Qué hicimos. En la Fase 2 de nuestro proyecto entrenamos tres modelos para anticipar qué estudiantes con reserva aprobada no pagarán la matrícula: una regresión logística regularizada, un gradient boosting y una logística híbrida. En esta actividad revisamos si esos modelos memorizan los datos de entrenamiento o si no aprenden lo suficiente. Registramos las métricas durante el entrenamiento, generamos cuatro tipos de curvas de aprendizaje, medimos el ajuste con dos reglas y probamos 7 estrategias de mejora con comparación antes y después, más dos filas de comprobación. Entrenamos con C2+C3 y validamos con C4. La cohorte de prueba (C5) no intervino, porque ya la habíamos evaluado una sola vez en la Fase 2.

Qué encontramos.

- El gradient boosting **sobreajusta**: su PR-AUC cae de 0,245 en entrenamiento a 0,103 en C4, un 58 % menos.
- La regresión logística y la logística híbrida no son modelos rígidos sino modelos en el **límite de la señal**. Son estables y solo alcanzan 1,28 y 1,41 veces el azar en C4, pero darles más capacidad no las mejora (la mejor PR-AUC con un C mayor cambia 0,000 en las dos) y más datos tampoco de forma concluyente. El control sobrerregularizado, en cambio, sí sale como falta de capacidad: con un C mayor su validación sube +0,016. La regla distingue los dos casos.
- Con la regla de veredicto fijada de antemano, **ninguna de las siete estrategias mejora ni empeora la PR-AUC en C4 de forma demostrable**. Las que más se acercan son E4a y E4b, que juntas reproducen el paso de la regresión logística a la logística híbrida, pero cada una por separado queda dentro del ruido.
- La contraprueba confirma la lectura de límite de señal: al dar más capacidad a la logística híbrida con interacciones (E6), su PR-AUC de entrenamiento salta de 0,126 a 0,227 y la de C4 casi no cambia (0,127). El modelo pasa a sobreajustar sin aprender nada útil.
- En la curva de pérdida, la ponderada (la que minimiza el gradient boosting) es mínima en la primera iteración y sube desde ahí, mientras que la sin ponderar baja. Las dos se leen distinto porque el modelo está entrenado con clases balanceadas y sus probabilidades no están calibradas.

Qué significa para el proyecto. Este diagnóstico respalda la decisión que tomamos en la Fase 2. El mejor modelo de la Fase 2 en C4 es la logística híbrida, con un Lift@k de 1,53, por debajo del 1,93 que obtuvo la regla D2 en esa misma cohorte. Ninguna estrategia lo mejora de forma demostrable, y el diagnóstico indica que el límite está en la información que tenemos al 20 de febrero, no en el tipo de modelo. Por eso mantenemos la regla D2 para priorizar el contacto. Lo observado en C4 son indicios, no pruebas: C4 ya se usó para seleccionar y calibrar, solo tiene 122 eventos y, como explicamos en la nota al final de la sección 6, el 1,93 de la regla depende de un sorteo.

Entregables. Cuaderno *overfitting_analysis.ipynb*, módulos *src/diagnostico.py* y *src/graficos_diagnostico.py* con pruebas automáticas, cinco figuras a 300 DPI y este reporte.

Cambios respecto de la primera versión

- **Dos tipos de subajuste.** La primera versión llamaba «subajuste» a la logística híbrida y en el texto decíamos que le faltaba señal, no capacidad. Ahora el diagnóstico tiene una segunda etapa que nombra cada caso por separado: «subajuste (falta capacidad)», «subajuste (faltan datos)» o «límite de señal» (sección 2.4).

- **Comparaciones limpias.** Cada estrategia cambia una sola cosa de un modelo de la Fase 2 que tiene el problema. E1 es ahora más L2 sobre el gradient boosting, E4 se separó en E4a (solo variables) y E4b (solo hiperparámetros) y E6 son interacciones sobre la logística híbrida. Las antiguas E1 y E6 quedan como fila de referencia y como contraprueba.
- **Robustez antes de hablar de mejora.** Cada diferencia lleva un intervalo bootstrap por familias, una réplica en otra partición (C2 → C3) y cinco semillas. Fijamos la regla de veredicto antes de repetir el cuaderno con datos reales.
- **Pérdida en escala común.** La Figura 1 usa la pérdida sin ponderar con la misma escala en los modelos de la Fase 2, una referencia sin modelo y, en los modelos balanceados, también la pérdida ponderada.

2. Metodología utilizada

2.1 Datos y particiones

Trabajamos con los registros seudonimizados de LEMAS. Cada fila es un estudiante con reserva aprobada al 20 de febrero y el evento es no pagar la matrícula hasta el 30 de abril. Respetamos el orden temporal en todas las particiones: entrenamos con cohortes anteriores y validamos con la siguiente. No usamos particiones al azar entre años porque filtrarían información del futuro.

Partición	Entrena con	Valida con	N entr.	Eventos entr.	N val.	Eventos val.	Uso
Diagnóstico	C2+C3	C4	2541	193	1374	122	Curvas, diagnóstico y medición de las estrategias
Interna	C2	C3	1236	112	1305	81	Elegir sin mirar C4 (parada temprana) y réplica de las estrategias

Puntaje y pérdida. La actividad pide una curva de exactitud o de puntaje. La tasa de eventos en C4 es 8,9 %, y con clases tan desbalanceadas la exactitud no nos sirve: un modelo que nunca detecta un caso acierta en casi todos. Por eso usamos como puntaje la **PR-AUC** (precisión promedio), en la que un ordenamiento al azar obtiene la tasa de eventos. Como **pérdida** usamos la entropía cruzada. La guardamos de dos formas: ponderada con los pesos de clase en los modelos balanceados (lo que esos modelos minimizan) y sin ponderar en todos. La Figura 1 usa la sin ponderar, con una escala común para los modelos de la Fase 2. Aun así, su altura no sirve para elegir entre modelos: los entrenados con clases balanceadas dan probabilidades infladas (sin calibrar) y por eso tienen más pérdida. Entre modelos comparamos con la PR-AUC; la pérdida la leemos por su forma: dónde es mínima y si después sube.

2.2 Seguimiento de métricas

Nuestros modelos son de scikit-learn. Programamos el seguimiento en *src/diagnostico.py* y guardamos cada medición en un mismo registro (*RegistroMetricas*: una fila por modelo, paso y conjunto):

- **Gradient boosting, por iteración.** *seguir_boosting* mide la pérdida y la PR-AUC de entrenamiento y de validación después de cada árbol añadido.
- **Regresiones logísticas, por iteración del optimizador.** scikit-learn no expone su estado intermedio, así que *seguir_logistica* entrena con un límite de iteraciones creciente hasta que el optimizador converge. Cada punto es un entrenamiento completo y el último es el modelo final.
- **learning_curve** de scikit-learn, para el efecto del tamaño del entrenamiento (5 submuestras por tamaño).
- **validation_curve** de scikit-learn, para el efecto de un hiperparámetro con el resto fijo.

2.3 Modelos analizados

Los modelos base son los tres de la Fase 2, con los hiperparámetros que eligió Optuna, que leímos del historial guardado. Al reentrenarlos comprobamos que su PR-AUC en la validación coincide con la tabla de la Fase 2 (diferencia máxima 0,0000). Añadimos dos modelos de control que no son candidatos y que definimos antes de ver los resultados: un gradient boosting sin regularizar, que debería sobreajustar, y una regresión logística con penalización L1 extrema, que debería subajustar. Nos sirven para comprobar que las reglas reconocen cada problema.

2.4 Reglas de diagnóstico

Diagnóstico	Patrón en las curvas	Regla cuantitativa
Sobreajuste	La brecha crece; el entrenamiento mejora y la validación se estanca o empeora	Brecha relativa de PR-AUC mayor que 30 %
Subajuste	Las dos curvas quedan juntas en un nivel pobre	Sin esa brecha, PR-AUC de validación menor que 1,5 veces el azar
Ajuste adecuado	Brecha pequeña y estable en un nivel útil	Ninguna de las dos condiciones anteriores
↳ Subajuste (falta capacidad)	Con más capacidad la validación sube	Curva D: con C o tasa de aprendizaje mayores que los actuales, la PR-AUC de validación sube al menos 0,005
↳ Subajuste (faltan datos)	Con más datos la validación sube	Más capacidad no ayuda, pero la curva C muestra una ganancia concluyente
↳ Límite de señal	Las curvas quedan juntas y bajas, y no suben ni con más capacidad ni con más datos	Ninguna de las dos condiciones anteriores: falta información en las variables, no flexibilidad en el modelo

Brecha relativa = (entrenamiento − validación) / entrenamiento. En las curvas durante el entrenamiento medimos además el paso con menor pérdida de validación y cuánto sube la pérdida después (lo contamos como deterioro si supera 0,01). Las filas con ↳ son una segunda etapa que solo se aplica a los modelos con subajuste: separa un modelo demasiado rígido de uno que ya extrae lo que las variables permiten, porque piden remedios distintos.

Alcance de estas reglas. Son reglas prácticas, no pruebas estadísticas. Fijamos los umbrales en *config.yaml* el 2 de octubre de 2026, antes de ejecutar el cuaderno con datos reales, aunque ya conocíamos las PR-AUC de entrenamiento y de C4 de la Fase 2. La brecha compara dos conjuntos cuya tasa de eventos puede ser distinta, y por eso en la Tabla 1 mostramos también cuántas veces supera al azar cada conjunto. En la Fase 2 habíamos usado una regla más simple (brecha absoluta mayor que 0,10; entrenamiento menor que 0,15), que puede diferir de esta en casos límite. La segunda etapa y la regla de veredicto de las estrategias (sección 5) las añadimos el 17 de octubre de 2026 (decisión D54), después de la primera versión de este reporte y antes de repetir el cuaderno con datos reales.

3. Resultados del diagnóstico

Modelo	PR-AUC entr.	PR-AUC C4	Brecha	Brecha relativa	Veces el azar entr. / C4	Más capacidad	Diagnóstico
Regresión logística	0,140	0,113	+0,026	19 %	1,84 / 1,28	0,000	**límite de señal**
Gradient boosting	0,245	0,103	+0,141	58 %	3,22 / 1,17	+0,006	**sobreajuste**
Logística híbrida	0,126	0,125	0,000	0 %	1,65 / 1,41	0,000	**límite de señal**
Control: árboles sin regularizar	0,998	0,088	+0,910	91 %	13,15 / 0,99	—	**sobreajuste**
Control: logística sobrerregularizada	0,076	0,089	−0,013	−17 %	1,00 / 1,00	+0,016	**subajuste (falta capacidad)**

Tabla 1. Diagnóstico por modelo (C2+C3 → C4). «Más capacidad»: cambio de la mejor PR-AUC de validación al aumentar C o la tasa de aprendizaje respecto del valor actual (curva D).

El gradient boosting es el caso más claro de sobreajuste. En entrenamiento ordena 3,22 veces mejor que el azar y en C4 solo 1,17 veces, así que casi todo lo que aprendió es particular de C2 y C3.

Las dos regresiones logísticas tienen el problema contrario en la primera etapa: la híbrida prácticamente no tiene brecha (0,126 frente a 0,125) y la regresión logística pierde un 19 %, menos que nuestro umbral del 30 %. Ninguna llega a 1,5 veces el azar en C4. En la primera versión las llamamos subajuste y a la vez decíamos que les faltaba señal; la segunda etapa resuelve esa contradicción. Con más capacidad (C hasta 100 en la curva D) la mejor PR-AUC de validación cambia 0,000 en las dos, y entre la mitad y el total del entrenamiento la ganancia es de +0,004 y +0,002, menor que la variación entre submuestras. Por eso las nombramos **límite de señal**. La exploración del cuaderno apunta en la misma dirección: la señal más fuerte, haber pagado tarde la matrícula anterior (21,9 % de no matrícula frente a 6,3 % de quienes pagaron en plazo), solo aparece en 32 estudiantes del entrenamiento.

Los controles se comportaron como esperábamos y ahora también comprueban la segunda etapa. Los árboles sin regularizar memorizan el entrenamiento (0,998) y en C4 quedan en el azar (0,088). La logística con penalización L1 extrema obtiene la tasa de eventos en ambos conjuntos, y al aumentar C su validación sube de 0,089 a 0,104: es falta de capacidad, y la regla la reconoce. La diferencia con las logísticas de la Fase 2 está en ese último paso: a ellas más C no les suma nada.

4. Análisis de curvas de aprendizaje

Generamos todas las figuras a 300 DPI. Azul es entrenamiento y rosa con marcadores redondos es validación. En las regresiones logísticas cada punto es un entrenamiento completo con ese límite de iteraciones.

4.1 Curva A: pérdida durante el entrenamiento

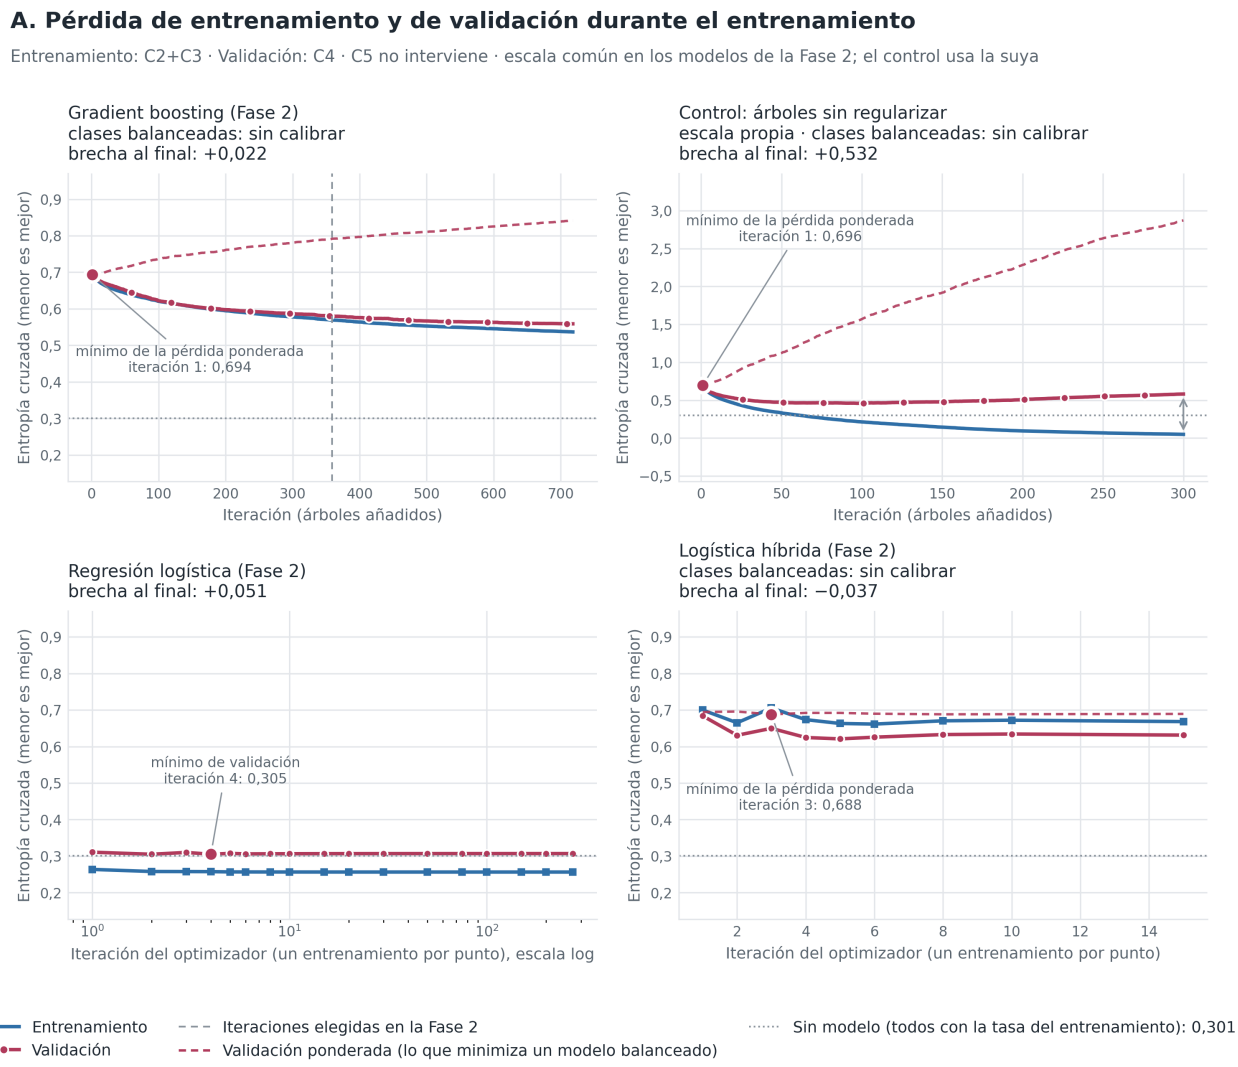


Figura 1. Pérdida sin ponderar de entrenamiento y de validación en cada paso. Los modelos de la Fase 2 comparten la escala; el control usa la suya. La línea punteada es la pérdida sin modelo. Los paneles marcados «clases balanceadas» tienen probabilidades sin calibrar: su pérdida es mayor por eso, no porque ordenen peor.

La Figura 1 usa la pérdida sin ponderar y la misma escala para los tres modelos de la Fase 2. La línea punteada (0,301) es la pérdida de no tener modelo: predecir a todos la tasa del entrenamiento. Solo la regresión logística, que no usa pesos de clase, queda a esa altura (0,305 en su mejor punto y 0,307 al converger). Los modelos balanceados quedan muy por encima porque sus probabilidades están infladas a propósito. Por eso la altura de la pérdida no sirve para comparar modelos; la comparación la hacemos con la PR-AUC. Un ejemplo de la tabla de estrategias: E4b cambia a clases balanceadas y la pérdida sin ponderar pasa de 0,300 a 0,631 con casi la misma PR-AUC.

En el gradient boosting las dos pérdidas cuentan historias distintas, y por eso dibujamos también la ponderada (línea discontinua), que es la que el modelo minimiza. La ponderada de validación es mínima en la primera iteración (0,694) y sube hasta 0,792 en las 359 iteraciones de la Fase 2 y 0,842 en la 718: es el patrón de sobreajuste. La sin ponderar, en cambio, baja de 0,692 a 0,580 y 0,559, porque el modelo va corrigiendo la inflación inicial de sus probabilidades. Leemos el

sobreajuste en la ponderada.

El control exagera el mismo patrón: su pérdida ponderada de validación pasa de 0,696 a 2,871 y la sin ponderar toca su mínimo (0,459) en la iteración 97 y sube después.

Las regresiones logísticas se aplanan casi de inmediato y la validación se estanca sin deteriorarse. La híbrida converge en 15 iteraciones con una pérdida ponderada de validación de 0,689, a centésimas de 0,693, que es la pérdida de asignar probabilidad 0,5 a todos con clases balanceadas.

4.2 Curva B: PR-AUC durante el entrenamiento

B. PR-AUC de entrenamiento y de validación durante el entrenamiento

Entrenamiento: C2+C3 · Validación: C4 · C5 no interviene · escala común en los modelos de la Fase 2; el control usa la suya

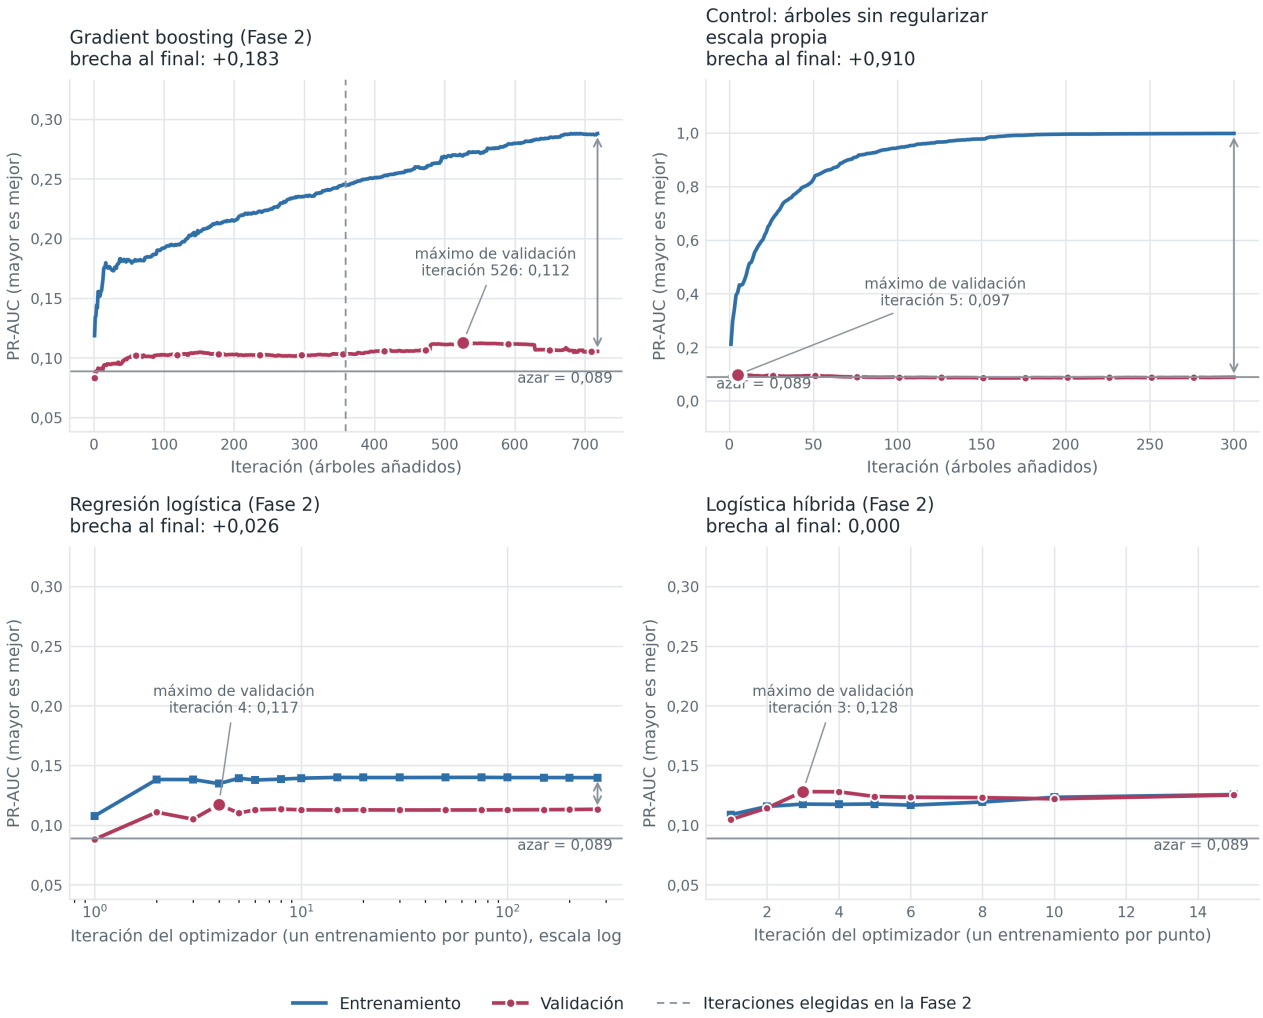


Figura 2. PR-AUC de entrenamiento y de validación en cada paso.

En PR-AUC el gradient boosting sigue subiendo en entrenamiento (0,245 en la iteración 359 y 0,288 en la 718), pero en validación llega pronto a 0,10 y se queda ahí: 0,100 en la iteración 50, 0,103 en la 359 y un máximo de 0,112 en la 526. La brecha crece con cada árbol que se añade.

La pérdida ponderada y la PR-AUC llevan a decisiones opuestas: según la pérdida, lo mejor en C4 sería quedarse en la primera iteración; según la PR-AUC, el orden mejora un poco hasta la iteración 526. La pérdida castiga las probabilidades mal calibradas y la PR-AUC solo mira el orden, que es lo que nos interesa para priorizar familias.

En las logísticas las dos curvas terminan juntas. La regresión logística queda en 0,140 y 0,113, y la híbrida en 0,126 y 0,125, con un máximo de validación de 0,128 en la tercera iteración. Ninguna se separa del azar (0,089) más de cuatro centésimas.

4.3 Curva C: tamaño del entrenamiento (opcional)

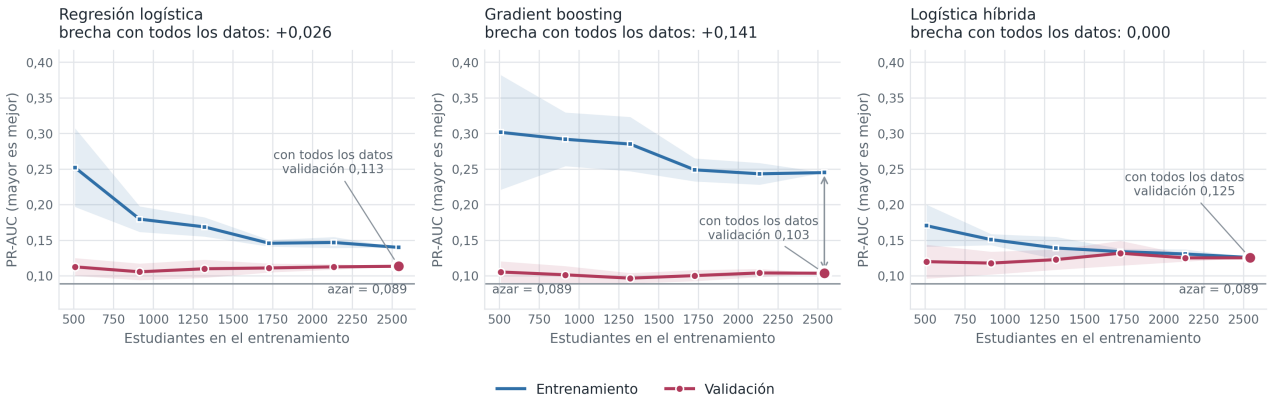


Figura 3. PR-AUC según el número de estudiantes en el entrenamiento. La banda es ±1 desviación entre submuestras.

Con 508 estudiantes la validación ya está casi donde termina con 2.541: 0,112 frente a 0,113 en la regresión logística, 0,105 frente a 0,103 en el gradient boosting y 0,120 frente a 0,125 en la híbrida. Entre la mitad y el total del entrenamiento el cambio es de +0,004, +0,007 y +0,002, siempre menor que la variación entre submuestras (±0,013, ±0,007 y ±0,014). Con estos datos no podemos afirmar que más datos ayuden.

Lo que sí cambia con el tamaño es el entrenamiento. Con pocos datos todos los modelos memorizan más (el gradient boosting llega a 0,30 con 508 estudiantes) y la brecha se cierra al añadir datos. En el gradient boosting no termina de cerrarse: con todos los datos sigue en 0,141.

Nuestra lectura es que el límite no está en la cantidad de datos. Otro año de registros con las mismas variables probablemente dejaría las curvas donde están. Para subirlas haría falta información distinta.

4.4 Curva D: hiperparámetros (opcional)

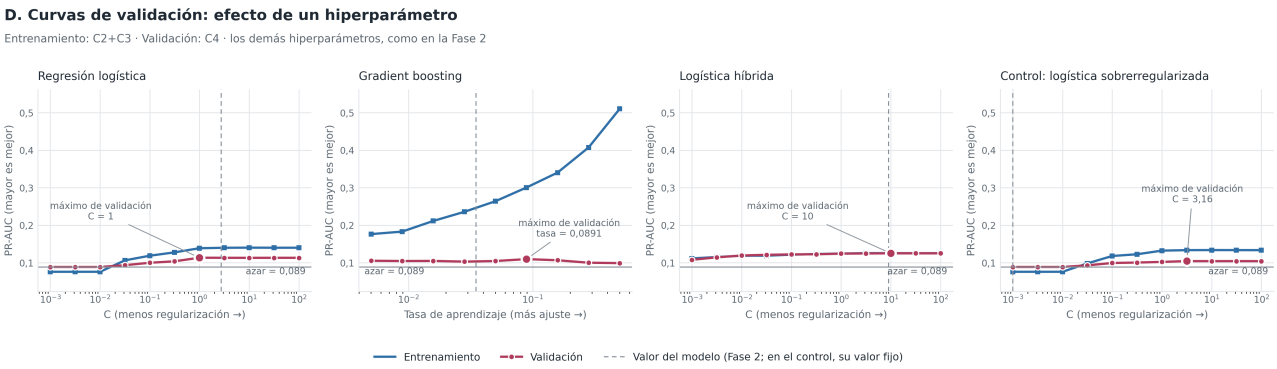


Figura 4. PR-AUC al variar un hiperparámetro; la línea discontinua marca el valor del modelo (en el control, su valor fijo).

En la regresión logística, con C menor o igual a 0,01 el modelo queda anulado (0,089 en C4, igual al azar). La validación sube hasta C = 1 (0,113) y desde ahí no cambia hasta C = 100. El valor de la Fase 2, 2,75, está en esa zona plana: más capacidad no ayuda.

En el gradient boosting la tasa de aprendizaje controla cuánto memoriza el modelo. Al subirla de 0,005 a 0,5 el entrenamiento pasa de 0,18 a 0,51, y la validación se mueve entre 0,099 y 0,110 sin una tendencia clara.

La logística híbrida es la más estable. Sus dos curvas van juntas en todo el rango y la validación sube despacio hasta 0,125 en C = 10, junto al valor de la Fase 2 (9,01). Con C = 100 sigue en 0,125.

El control sobrerregularizado es la referencia para leer estas curvas. Parte del azar con C = 0,001 y su validación sube hasta 0,104 con C = 3,16. Es lo que esperaríamos ver si a las logísticas de la Fase 2 les faltara capacidad, y no lo vemos.

En los tres modelos de la Fase 2 el valor que eligió Optuna está cerca del máximo de validación. El problema no es una mala elección de hiperparámetros.

5. Estrategias implementadas y resultados

Implementamos 7 estrategias (la actividad pide al menos dos). Cada una parte de un modelo de la Fase 2 que tiene el problema que busca corregir y **cambia una sola cosa**, para poder atribuirle la diferencia. Por eso separamos la antigua E4 en E4a (solo las variables de D2) y E4b (solo los hiperparámetros del híbrido). Dos filas más no son estrategias: la **referencia** (del control sin regularizar al gradient boosting de la Fase 2, donde cambian varias cosas) y la **contraprueba** (más iteraciones a un modelo que no tiene subajuste). En la parada temprana elegimos las iteraciones en la validación interna (C2 → C3), de modo que solo puede recortar.

Regla de veredicto. Con 122 eventos en C4, una diferencia pequeña puede ser ruido. Decimos que una estrategia **mejora** la PR-AUC solo si se cumplen cuatro condiciones: (1) el cambio en C4 llega a 0,005; (2) el intervalo de confianza del 95 % de la diferencia no incluye el cero (2000 réplicas bootstrap que remuestrean familias y comparan los dos modelos con las mismas familias); (3) la réplica en C2 → C3 va en el mismo sentido; y (4) con 5 semillas la diferencia va en el mismo sentido. **Empeora** es lo simétrico; en otro caso, **sin diferencia demostrable**. Fijamos esta regla antes de repetir el cuaderno con datos reales. Dos advertencias: en la partición de la réplica eligió Optuna los hiperparámetros de la Fase 2, así que favorece al modelo ya afinado (y en E2 es circular); y el gradient boosting y la logística con lbfgs no dependen de la semilla, de modo que las semillas solo mueven la logística con saga y el desempate del Lift@k.

Estrategia y cambio aplicado	PR-AUC C4 diferencia [IC 95 %]	Réplica C3	Brecha	Lift@k	Veredicto
E1 · Más regularización (contra el sobreajuste) L2: 4,25 → 42,5; lo demás igual	0,103 → 0,107 +0,003 [−0,004; +0,015]	−0,009	+0,141 → +0,108 se reduce	1,06 → 1,13 semillas: +0,07 a +0,07	**sin diferencia demostrable**
E2 · Parada temprana (contra el sobreajuste) iteraciones: 359 → 20, elegidas por pérdida en la validación interna	0,103 → 0,095 −0,009 [−0,033; +0,010]	−0,008	+0,141 → +0,080 se reduce	1,06 → 0,80 semillas: −0,33 a −0,20	**sin diferencia demostrable**
E3 · Árboles más pequeños (contra el sobreajuste) profundidad 3 → 2; hojas 6 → 4; mismas iteraciones; misma L2	0,103 → 0,106 +0,002 [−0,008; +0,017]	−0,008	+0,141 → +0,098 se reduce	1,06 → 0,80 semillas: −0,27 a −0,27	**sin diferencia demostrable**
E4a · Variables de D2 (solo variables) (contra el subajuste) variables de la logística híbrida (pago tardío, reserva extraordinaria, atrasos por tramos…) con el clasificador y los hiperparámetros de la regresión logística	0,113 → 0,120 +0,007 [−0,016; +0,037]	−0,022	+0,026 → +0,013 se reduce	1,40 → 1,33 semillas: −0,07 a −0,07	**sin diferencia demostrable**

Estrategia y cambio aplicado	PR-AUC C4 diferencia [IC 95 %]	Réplica C3	Brecha	Lift@k	Veredicto
E4b · Hiperparámetros del híbrido (solo hiperparámetros) (contra el subajuste) mismas variables; C 2,75 → 9,01, clases balanceadas, penalización L2	0,120 → 0,125 +0,005 [−0,001; +0,013]	+0,004	+0,013 → 0,000 se reduce	1,33 → 1,53 semillas: +0,20 a +0,20	**sin diferencia demostrable**
E5 · Menos regularización (contra el subajuste) C: 2,75 → 27,5	0,113 → 0,113 0,000 [−0,001; +0,001]	0,000	+0,026 → +0,027 sin cambio apreciable	1,40 → 1,46 semillas: +0,07 a +0,07	**sin diferencia demostrable**
E6 · Interacciones (contra el subajuste) productos de dos variables de la logística híbrida; mismos hiperparámetros	0,125 → 0,127 +0,002 [−0,032; +0,040]	−0,004	0,000 → +0,100 aumenta	1,53 → 1,53 semillas: 0,00 a 0,00	**sin diferencia demostrable**
Referencia · Regularización de la Fase 2 búsqueda con Optuna (Fase 2): tasa de aprendizaje 0,1 → 0,0351; profundidad sin límite → 3; mínimo de muestras por hoja 5 → 101; L2 0 → 4,25	0,088 → 0,103 +0,015 [−0,003; +0,044]	+0,018	+0,910 → +0,141 se reduce	1,00 → 1,06 semillas: +0,07 a +0,07	**sin diferencia demostrable**
Contraprueba · Más iteraciones iteraciones: 359 → 718	0,103 → 0,105 +0,002 [−0,008; +0,015]	+0,002	+0,141 → +0,183 aumenta	1,06 → 0,86 semillas: −0,20 a −0,20	**sin diferencia demostrable**

Tabla 2. Antes → después de cada estrategia. «Réplica»: diferencia de PR-AUC en la partición C2 → C3. «Semillas»: rango de la diferencia de Lift@k con cada semilla del desempate. El veredicto aplica la regla de cuatro condiciones; el efecto sobre la brecha se juzga por su tamaño (valor absoluto).

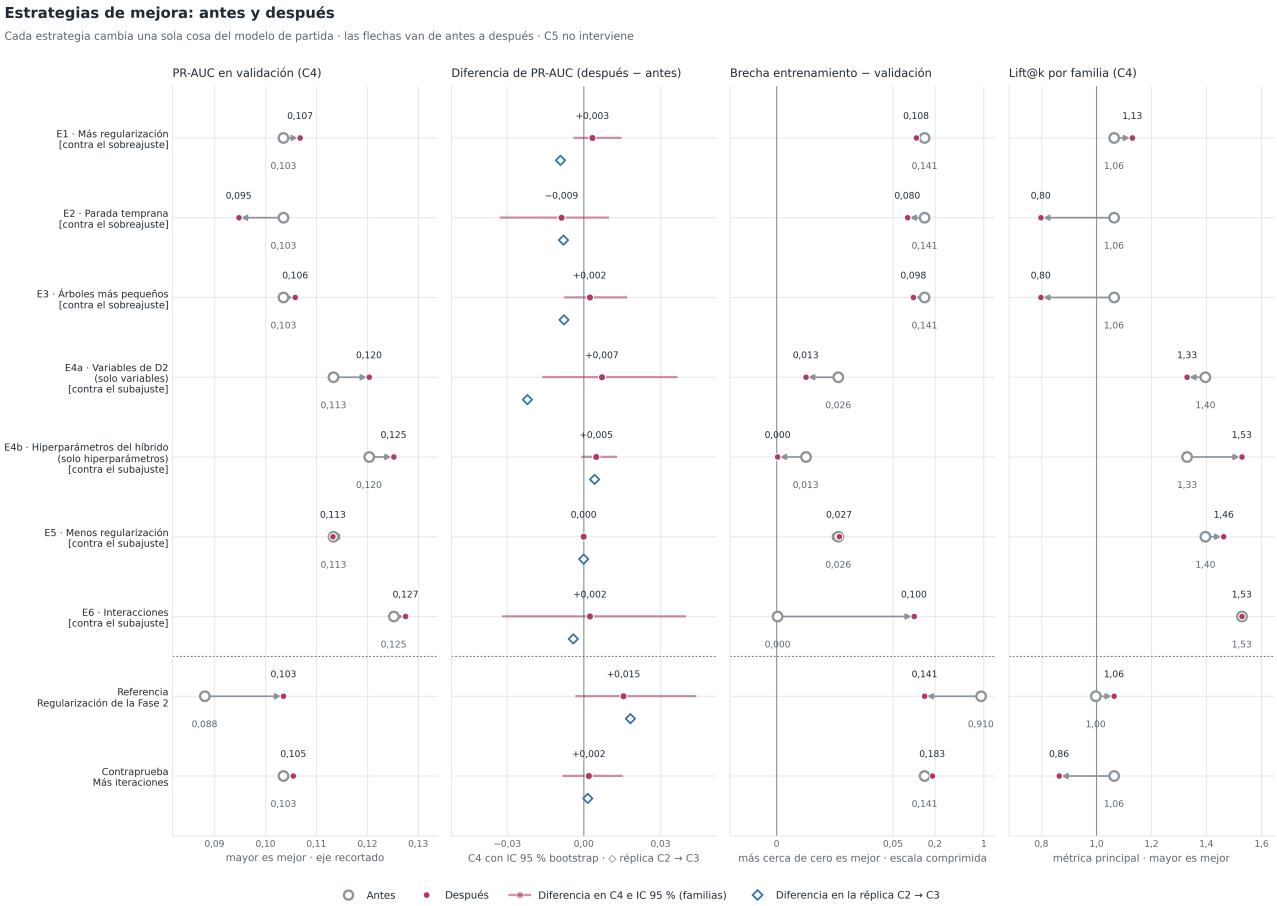


Figura 5. Efecto de cada estrategia sobre la PR-AUC de validación, la brecha y el Lift@k por familia; el segundo panel muestra la diferencia de PR-AUC con su IC 95 % y la réplica.

Contra el sobreajuste del gradient boosting, las tres estrategias reducen la brecha (de 0,141 a 0,108 con E1, a 0,080 con E2 y a 0,098 con E3), pero ninguna mejora la validación de forma demostrable. E1, multiplicar la L2 por diez, mueve la PR-AUC en C4 +0,003 con un intervalo de [−0,004; +0,015], y en la réplica va en sentido contrario (−0,009). E3, árboles de dos niveles y cuatro hojas, se queda en +0,002 y su Lift@k baja de 1,06 a 0,80.

La parada temprana (E2) recortó el entrenamiento de 359 a 20 iteraciones, elegidas por pérdida en la validación interna. La PR-AUC bajó −0,009 en C4 y −0,008 en la réplica, y el Lift@k cayó a 0,80. Con el intervalo [−0,033; +0,010] no lo podemos llamar un empeoramiento demostrable, pero el sentido coincide en las dos particiones. La curva A lo explica: la pérdida ponderada sube desde el primer árbol, así que el criterio se detiene antes de que el modelo aprenda a ordenar.

Contra el límite de las logísticas, separar la antigua E4 en dos pasos fue lo más informativo. Cambiar solo las variables (E4a) sube la PR-AUC de 0,113 a 0,120, pero con un intervalo de [−0,016; +0,037] y una réplica de −0,022. Cambiar después solo los hiperparámetros del híbrido (E4b) la lleva de 0,120 a 0,125 con un intervalo de [−0,001; +0,013] y una réplica de +0,004: es la que más se acerca, pero el cambio no llega a 0,005 y el intervalo toca el cero. El Lift@k sube de 1,33 a 1,53 en este paso.

E5, multiplicar C por diez en la regresión logística, no cambia nada (0,000), porque el modelo ya estaba en la zona plana de la curva D.

E6 da más capacidad a la logística híbrida con interacciones entre pares de variables. La PR-AUC de entrenamiento sube de 0,126 a 0,227 y la de C4 solo a 0,127, con el intervalo más ancho de todos ([−0,032; +0,040]). El diagnóstico pasa de subajuste a sobreajuste. Es justo lo que esperábamos de un modelo en el límite de la señal: más flexibilidad solo le permite memorizar.

Las dos filas que no son estrategias se leen como comprobaciones. La referencia (del control sin regularizar al gradient boosting de la Fase 2) cierra la brecha de 0,910 a 0,141 y sube la PR-AUC +0,015, con una réplica de +0,018; aun así el intervalo, [−0,003; +0,044], toca el cero, lo que muestra cuán exigente es la regla con 122 eventos. La contraprueba (de 359 a 718 iteraciones) sube la brecha a 0,183 y baja el Lift@k a 0,86.

Los modelos de árboles y la logística con lbfgs no dependen de la semilla, así que las cinco semillas dan la misma diferencia de PR-AUC. Solo el desempate del Lift@k cambia: en E2 su caída va de −0,33 a −0,20 según la semilla.

6. Conclusiones y recomendaciones futuras

Conclusiones

- El gradient boosting sobreajusta. Las dos regresiones logísticas no subajustan por rigidez: están en el límite de la señal de las variables disponibles al 20 de febrero.
- Ninguna de las siete estrategias cambia la PR-AUC en C4 de forma demostrable. Reducir el sobreajuste cierra la brecha pero no agrega señal, y dar más capacidad a un modelo en el límite de la señal solo lo hace memorizar (E6).
- Separar variables e hiperparámetros (E4a y E4b) mostró que ninguno de los dos pasos es concluyente por sí solo. Lo que en la primera versión llamamos la única mejora útil era, con esta regla, una diferencia dentro del ruido.
- Los hiperparámetros de la Fase 2 estaban bien elegidos: en los tres modelos el valor de Optuna está cerca del máximo de la curva D.
- La decisión del proyecto no cambia. El mejor modelo llega a un Lift@k de 1,53 en C4 y la regla D2 a 1,93 con el sorteo que usamos (ver la nota posterior). C5 no intervino en este análisis.

Qué aprendimos

Antes de esta actividad leíamos el sobreajuste como un solo número, la diferencia entre entrenamiento y validación. Las curvas nos mostraron más: cuándo empieza, si la validación llega a mejorar en algún momento y si un rendimiento bajo se debe a un modelo rígido o a variables que dicen poco. La revisión de la primera versión nos enseñó dos cosas más. Primero, que una etiqueta debe decir lo mismo que el análisis: «subajuste» y «falta de señal» piden remedios distintos. Segundo, que con 122 eventos una diferencia de una centésima no basta para hablar de mejora; hay que fijar antes la regla con la que se va a decidir y aceptar que la respuesta puede ser «no se puede demostrar».

Limitaciones

- Comparamos las estrategias en C4, que ya habíamos usado para seleccionar y calibrar en la Fase 2, y las replicamos en C3, donde Optuna eligió los hiperparámetros. Ninguna de las dos cohortes es independiente; la réplica favorece al modelo ya afinado y es circular para E2.
- El bootstrap mide cuánto cambiaría cada diferencia con otras familias de la misma cohorte, no cuánto cambia entre años. Las tasas de evento cambian entre ciclos (9,1 % en C2 y 6,2 % en C3).
- La regla de veredicto y la segunda etapa del diagnóstico las fijamos antes de repetir el cuaderno, pero después de ver la primera versión de estos resultados. Los umbrales de la primera etapa los fijamos conociendo los resultados de la Fase 2.
- La ganancia por capacidad toma el mejor de varios valores de C en C4, así que tiende a exagerar. Que aun así sea 0,000 en las dos logísticas refuerza la lectura de límite de señal.
- La comparación con la regla D2 usa un solo sorteo entre familias con el mismo puntaje. Con otros sorteos su Lift@k en C4 va de 1,53 a 1,99, con una media de 1,75.

Recomendaciones

- Repetir este diagnóstico cada mayo con la cohorte que cierra, que no habrá participado en ninguna decisión, y aplicar ahí la misma regla de veredicto a E4a y E4b.
- Si volvemos a entrenar un gradient boosting, elegir el número de iteraciones con la métrica de ordenamiento (PR-AUC o Lift@k) en la validación interna, y no con la pérdida.
- Buscar información nueva antes que modelos más complejos. El análisis de alcance encontró una que ya está en los registros: quién sigue sin pagar a mitad de campaña. Falta probarla en la próxima campaña.
- Mantener la regla D2 para priorizar mientras ningún modelo la supere en una cohorte que no haya participado en las decisiones.
- Informar el Lift@k de una regla con empates como el promedio de varios sorteos, con su mínimo y su máximo, y no con un sorteo solo.

Nota posterior: el sorteo entre familias empatadas

El 3 de octubre, al analizar por qué la lista no llega a más familias, revisamos cómo se forma la lista de la regla D2. Muchas familias tienen el mismo puntaje y el corte de la lista cae entre ellas, así que el orden entre empatadas se decide con un sorteo de semilla fija. Repetimos ese sorteo cien veces. En C4, la lista de D2 alcanza entre el 24 % y el 32 % de los casos según cómo caiga, lo que equivale a un Lift@k de 1,53 a 1,99. La media es 28 % y 1,75. Con el sorteo que usamos en la Fase 2 fue 31 % y 1,93, cerca del extremo alto.

En promedio la regla sigue por encima de la logística híbrida (1,75 frente a 1,53), pero en el extremo bajo la iguala (24 % de los casos). La ventaja de D2 sobre el mejor modelo en C4 es entonces menor y menos firme de lo que sugiere una sola cifra. Lo que sostiene la decisión es la prueba final en C5, que hicimos una sola vez en la Fase 2 y no repetimos: ahí la regla casi duplicó al azar y la logística híbrida no lo superó.

Esta nota no cambia ninguna cifra del diagnóstico, que trata de los modelos y no de la regla. El análisis completo está en docs/alcance_lista.md y en el cuaderno 06_alcance_lista.

7. Referencias técnicas

[1] F. Pedregosa *et al.*, «Scikit-learn: Machine Learning in Python», *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.

[2] scikit-learn developers, «Validation curves: plotting scores to evaluate models», Guía de usuario de scikit-learn. https://scikit-learn.org/stable/modules/learning_curve.html

[3] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2.ª ed. Nueva York: Springer, 2009, cap. 7.

[4] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016, caps. 5 y 7.

[5] L. Prechelt, «Early Stopping — But When?», en *Neural Networks: Tricks of the Trade*, LNCS 1524. Berlín: Springer, 1998, pp. 55-69.

[6] J. H. Friedman, «Greedy function approximation: A gradient boosting machine», *The Annals of Statistics*, vol. 29, n.º 5, pp. 1189-1232, 2001.

[7] H. Zou y T. Hastie, «Regularization and variable selection via the elastic net», *Journal of the Royal Statistical Society: Series B*, vol. 67, n.º 2, pp. 301-320, 2005.

[8] T. Akiba, S. Sano, T. Yanase, T. Ohta y M. Koyama, «Optuna: A Next-generation Hyperparameter Optimization Framework», en *Proc. 25th ACM SIGKDD*, 2019, pp. 2623-2631.

[9] T. Saito y M. Rehmsmeier, «The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets», *PLoS ONE*, vol. 10, n.º 3, e0118432, 2015.

Código y resultados: github.com/ggranizo2507/prediccion-matricula-lemas (*notebooks/overfitting_analysis.ipynb*, *src/diagnostico.py*, *results/*).