

Diagnóstico de sobreajuste y subajuste

Reporte técnico · Actividad de la semana 3

Proyecto: Predicción de matrícula y continuidad estudiantil, Unidad Educativa LEMAS

Guillermo Granizo y José Ulloa · Maestría en Inteligencia Artificial, UEES · 3 de octubre de 2026

1. Resumen ejecutivo

Qué hicimos. En la Fase 2 de nuestro proyecto entrenamos tres modelos para anticipar qué estudiantes con reserva aprobada no pagarán la matrícula: una regresión logística regularizada, un gradient boosting y una logística híbrida. En esta actividad revisamos si esos modelos memorizan los datos de entrenamiento o si no aprenden lo suficiente. Registramos las métricas durante el entrenamiento, generamos cuatro tipos de curvas de aprendizaje, medimos el ajuste con dos reglas y probamos 6 estrategias de mejora con comparación antes y después. Entrenamos con C2+C3 y validamos con C4. La cohorte de prueba (C5) no intervino, porque ya la habíamos evaluado una sola vez en la Fase 2.

Qué encontramos.

- Ninguno de los tres modelos de la Fase 2 tiene un ajuste adecuado. El gradient boosting sobreajusta: su PR-AUC cae de 0,245 en entrenamiento a 0,103 en C4, una pérdida del 58 %. La regresión logística y la logística híbrida subajustan: son estables, pero en C4 solo alcanzan 1,28 y 1,41 veces el azar.
- Lo que más nos llamó la atención fue la curva de pérdida del gradient boosting. En C4 la pérdida es mínima en la primera iteración (0,694) y desde ahí solo sube, hasta 0,792 en las 359 iteraciones que usamos en la Fase 2.
- De las seis estrategias, dos mejoraron la PR-AUC en C4 (E1 y E4), una la empeoró (E2) y tres no la cambiaron de forma apreciable. Las tres estrategias contra el sobreajuste redujeron la brecha, pero ninguna sacó al gradient boosting del sobreajuste.
- La única mejora que consideramos útil vino de la ingeniería de variables (E4). Al pasar de la regresión logística a la logística híbrida, la PR-AUC subió de 0,113 a 0,125 y el Lift@k de 1,40 a 1,53, sin brecha entre entrenamiento y validación.
- Tener más datos del mismo tipo no parece la solución. Entre la mitad y el total del entrenamiento la validación casi no cambia, y la diferencia es menor que la variación entre submuestras en los tres modelos.

Qué significa para el proyecto. Este diagnóstico respalda la decisión que tomamos en la Fase 2. El mejor modelo después de todas las estrategias es la logística híbrida, con un Lift@k de 1,53 en C4, por debajo del 1,93 que obtuvo la regla D2 en esa misma cohorte. Por eso mantenemos la regla D2 para priorizar el contacto. Lo que observamos en C4 son indicios y no pruebas: C4 ya se usó para seleccionar y calibrar, solo tiene 122 eventos y, como explicamos en la nota al final de la sección 6, el 1,93 de la regla depende de un sorteo.

Entregables. Cuaderno *overfitting_analysis.ipynb*, módulos *src/diagnostico.py* y *src/graficos_diagnostico.py* con pruebas automáticas, cinco figuras a 300 DPI y este reporte.

2. Metodología utilizada

2.1 Datos y particiones

Trabajamos con los registros seudonimizados de LEMAS. Cada fila es un estudiante con reserva aprobada al 20 de febrero y el evento es no pagar la matrícula hasta el 30 de abril. Respetamos el orden temporal en todas las particiones: entrenamos con cohortes anteriores y validamos con la siguiente. No usamos particiones al azar entre años porque filtrarían información del futuro.

Partición	Entrena con	Valida con	N entr.	Eventos entr.	N val.	Eventos val.	Uso
Diagnóstico	C2+C3	C4	2541	193	1374	122	Curvas, diagnóstico y medición de las estrategias
Interna	C2	C3	1236	112	1305	81	Elegir sin mirar C4 (parada temprana)

Puntaje y pérdida. La actividad pide una curva de exactitud o de puntaje. La tasa de eventos en C4 es 8,9 %, y con clases tan desbalanceadas la exactitud no nos sirve: un modelo que nunca detecta un caso acierta en casi todos. Por eso usamos como puntaje la **PR-AUC** (precisión promedio), en la que un ordenamiento al azar obtiene la tasa de eventos. Como **pérdida** usamos la entropía cruzada. En los modelos entrenados con clases balanceadas la ponderamos igual que en el entrenamiento, así que la pérdida solo se puede comparar entre curvas del mismo modelo.

2.2 Seguimiento de métricas

Nuestros modelos son de scikit-learn. Programamos el seguimiento en `src/diagnostico.py` y guardamos cada medición en un mismo registro (*RegistroMetricas*: una fila por modelo, paso y conjunto):

- **Gradient boosting, por iteración.** *seguir_boosting* mide la pérdida y la PR-AUC de entrenamiento y de validación después de cada árbol añadido.
- **Regresiones logísticas, por iteración del optimizador.** scikit-learn no expone su estado intermedio, así que *seguir_logistica* entrena con un límite de iteraciones creciente hasta que el optimizador converge. Cada punto es un entrenamiento completo y el último es el modelo final.
- **learning_curve** de scikit-learn, para el efecto del tamaño del entrenamiento (5 submuestras por tamaño).
- **validation_curve** de scikit-learn, para el efecto de un hiperparámetro con el resto fijo.

2.3 Modelos analizados

Los modelos base son los tres de la Fase 2, con los hiperparámetros que eligió Optuna, que leímos del historial guardado. Al reentrenarlos comprobamos que su PR-AUC en la validación coincide con la tabla de la Fase 2 (diferencia máxima 0,0000). Añadimos dos modelos de control que no son candidatos y que definimos antes de ver los resultados: un gradient boosting sin regularizar, que debería sobreajustar, y una regresión logística con penalización L1 extrema, que debería subajustar. Nos sirven para comprobar que las reglas reconocen cada problema.

2.4 Reglas de diagnóstico

Diagnóstico	Patrón en las curvas	Regla cuantitativa
Sobreajuste	La brecha crece; el entrenamiento mejora y la validación se estanca o empeora	Brecha relativa de PR-AUC mayor que 30 %
Subajuste	Las dos curvas quedan juntas en un nivel pobre	Sin esa brecha, PR-AUC de validación menor que 1,5 veces el azar
Ajuste adecuado	Brecha pequeña y estable en un nivel útil	Ninguna de las dos condiciones anteriores

Brecha relativa = (entrenamiento – validación) / entrenamiento. En las curvas durante el entrenamiento medimos además el paso con menor pérdida de validación y cuánto sube la pérdida

después (lo contamos como deterioro si supera 0,01). Decimos que una estrategia mejora o empeora solo si la PR-AUC cambia al menos 0,005.

Alcance de estas reglas. Son reglas prácticas, no pruebas estadísticas. Fijamos los umbrales en `config.yaml` el 2 de octubre de 2026, antes de ejecutar el cuaderno con datos reales, aunque ya conocíamos las PR-AUC de entrenamiento y de C4 de la Fase 2. La brecha compara dos conjuntos cuya tasa de eventos puede ser distinta, y por eso en la Tabla 1 mostramos también cuántas veces supera al azar cada conjunto. En la Fase 2 habíamos usado una regla más simple (brecha absoluta mayor que 0,10; entrenamiento menor que 0,15), que puede diferir de esta en casos límite.

3. Resultados del diagnóstico

Modelo	Rol	PR-AUC entr.	PR-AUC C4	Brecha	Brecha relativa	Veces el azar (entr.)	Veces el azar (C4)	Diagnóstico
Regresión logística	Fase 2	0,140	0,113	+0,026	19 %	1,84	1,28	subajuste
Gradient boosting	Fase 2	0,245	0,103	+0,141	58 %	3,22	1,17	sobreajuste
Logística híbrida	Fase 2	0,126	0,125	0,000	0 %	1,65	1,41	subajuste
Control: árboles sin regularizar	control	0,998	0,088	+0,910	91 %	13,15	0,99	sobreajuste
Control: logística sobreregularizada	control	0,076	0,089	-0,013	-17 %	1,00	1,00	subajuste

Tabla 1. Diagnóstico por modelo (C2+C3 → C4).

El gradient boosting es el caso más claro. En entrenamiento ordena 3,22 veces mejor que el azar y en C4 solo 1,17 veces, así que casi todo lo que aprendió es particular de C2 y C3. Por la tabla de la Fase 2 esperábamos sobreajuste, pero no que la validación quedara tan cerca del azar.

Las dos regresiones logísticas tienen el problema contrario. La híbrida prácticamente no tiene brecha (0,126 frente a 0,125) y la regresión logística pierde un 19 %, menos que nuestro umbral del 30 %. Son modelos estables, pero ninguno llega a 1,5 veces el azar en C4 y por eso la regla los clasifica como subajuste. Creemos que no les falta capacidad sino señal. La exploración del cuaderno apunta en la misma dirección: la señal más fuerte, haber pagado tarde la matrícula anterior (21,9 % de no matrícula frente a 6,3 % de quienes pagaron en plazo), solo aparece en 32 estudiantes del entrenamiento.

Los dos modelos de control se comportaron como esperábamos. Los árboles sin regularizar memorizan el entrenamiento (0,998) y en C4 quedan en el azar (0,088). La logística con penalización L1 extrema anula sus coeficientes y obtiene la tasa de eventos en ambos conjuntos. Esto nos da confianza en la regla para los casos claros. No dice nada de los casos cercanos a los umbrales, como la logística híbrida, que con 1,41 queda cerca del 1,5.

4. Análisis de curvas de aprendizaje

Generamos todas las figuras a 300 DPI. Azul es entrenamiento y rosa con marcadores redondos es validación. En las regresiones logísticas cada punto es un entrenamiento completo con ese límite de iteraciones.

4.1 Curva A: pérdida durante el entrenamiento

A. Pérdida de entrenamiento y de validación durante el entrenamiento

Entrenamiento: C2+C3 · Validación: C4 · C5 no interviene · cada panel tiene su propia escala




Figura 1. Pérdida de entrenamiento y de validación en cada paso. Cada panel tiene su propia escala.

En el gradient boosting la pérdida de entrenamiento baja sin parar (de 0,691 en la primera iteración a 0,559 en la 359 y a 0,523 en la 718), mientras la de validación sube desde el primer árbol: 0,694, 0,792 y 0,842 en esas mismas iteraciones. Es el patrón de sobreajuste que describe la actividad, con una particularidad: la validación nunca llega a mejorar. Como este modelo se entrena con clases balanceadas, 0,693 es la pérdida de asignar probabilidad 0,5 a todos los estudiantes. En C4 sus probabilidades no son mejores que no predecir nada.

El control exagera el mismo patrón: su pérdida de validación pasa de 0,696 a 2,871.

Las regresiones logísticas muestran la otra forma típica. Las dos curvas se aplanan casi de inmediato y quedan paralelas. La regresión logística converge en 273 iteraciones, pero desde la sexta la pérdida de validación se queda entre 0,306 y 0,307, después de haber tocado 0,305 en la cuarta. La híbrida converge en 15, con 0,689 en validación y 0,668 en entrenamiento. También aquí la validación queda apenas por debajo de 0,693.

4.2 Curva B: PR-AUC durante el entrenamiento

B. PR-AUC de entrenamiento y de validación durante el entrenamiento

Entrenamiento: C2+C3 · Validación: C4 · C5 no interviene · cada panel tiene su propia escala




Figura 2. PR-AUC de entrenamiento y de validación en cada paso.

En PR-AUC el gradient boosting sigue subiendo en entrenamiento (0,245 en la iteración 359 y 0,288 en la 718), pero en validación llega pronto a 0,10 y se queda ahí: 0,100 en la iteración 50, 0,103 en la 359 y un máximo de 0,112 en la 526. La brecha crece con cada árbol que se añade.

Aquí encontramos algo que no esperábamos: la pérdida y la PR-AUC no cuentan la misma historia. Según la pérdida, lo mejor en C4 sería quedarse en la primera iteración. Según la PR-AUC, el orden mejora un poco hasta la iteración 526. La pérdida castiga las probabilidades mal calibradas y la PR-AUC solo mira el orden, que es lo que nos interesa para priorizar familias.

En las logísticas las dos curvas terminan juntas. La regresión logística queda en 0,140 y 0,113, y la híbrida en 0,126 y 0,125, con un máximo de validación de 0,128 en la tercera iteración. Ninguna se separa del azar (0,089) más de cuatro centésimas.

4.3 Curva C: tamaño del entrenamiento (opcional)

C. Curvas de aprendizaje según el tamaño del entrenamiento

Submuestras de C2+C3 · Validación fija: C4 · banda = ± 1 desviación entre submuestras




Figura 3. PR-AUC según el número de estudiantes en el entrenamiento. La banda es ± 1 desviación entre submuestras.

Con 508 estudiantes la validación ya está casi donde termina con 2.541: 0,112 frente a 0,113 en la regresión logística, 0,105 frente a 0,103 en el gradient boosting y 0,120 frente a 0,125 en la híbrida. Entre la mitad y el total del entrenamiento el cambio es de +0,004, +0,007 y +0,002, siempre menor que la variación entre submuestras ($\pm 0,013$, $\pm 0,007$ y $\pm 0,014$). Con estos datos no podemos afirmar que más datos ayuden.

Lo que sí cambia con el tamaño es el entrenamiento. Con pocos datos todos los modelos memorizan más (el gradient boosting llega a 0,30 con 508 estudiantes) y la brecha se cierra al añadir datos. En el gradient boosting no termina de cerrarse: con todos los datos sigue en 0,141.

Nuestra lectura es que el límite no está en la cantidad de datos. Otro año de registros con las mismas variables probablemente dejaría las curvas donde están. Para subirlas haría falta información distinta.

4.4 Curva D: hiperparámetros (opcional)

D. Curvas de validación: efecto de un hiperparámetro

Entrenamiento: C2+C3 · Validación: C4 · los demás hiperparámetros, como en la Fase 2




Figura 4. PR-AUC al variar un hiperparámetro; la línea discontinua marca el valor de la Fase 2.

En la regresión logística, con C menor o igual a 0,01 el modelo queda anulado (0,089 en C4, igual al azar). La validación sube hasta $C = 1$ (0,113) y desde ahí no cambia. El valor de la Fase 2, 2,75, está en esa zona plana, así que quitar regularización no ayuda.

En el gradient boosting la tasa de aprendizaje controla cuánto memoriza el modelo. Al subirla de 0,005 a 0,5 el entrenamiento pasa de 0,18 a 0,51, y la validación se mueve entre 0,099 y 0,110 sin una tendencia clara. El máximo está en una tasa de 0,089, no muy lejos del 0,035 de la Fase 2.

La logística híbrida es la más estable. Sus dos curvas van juntas en todo el rango y la validación sube despacio hasta 0,125 en $C = 10$, junto al valor de la Fase 2 (9,01).

En los tres casos el valor que eligió Optuna está cerca del máximo de validación. El problema de estos modelos no es una mala elección de hiperparámetros.

5. Estrategias implementadas y resultados

Implementamos 6 estrategias (la actividad pide al menos dos) y las medimos todas en la misma partición. Cada una aplica un solo tipo de cambio (E3 ajusta a la vez los hiperparámetros de complejidad), con dos excepciones: E1 parte de un modelo de control y no de un candidato, y E4 cambia las variables y también los hiperparámetros. En la parada temprana elegimos las iteraciones por menor pérdida en la validación interna ($C2 \rightarrow C3$), de modo que solo puede recortar el entrenamiento.

Estrategia y cambio aplicado	PR-AUC C4	Brecha	Lift@k	Diagnóstico
E1 · Regularización y menor complejidad (contra el sobreajuste) búsqueda con Optuna (Fase 2): tasa de aprendizaje 0,1 $\rightarrow$ 0,0351; profundidad sin límite $\rightarrow$ 3; mínimo de muestras por hoja 5 $\rightarrow$ 101; L2 0 $\rightarrow$ 4,25	0,088 $\rightarrow$ 0,103 mejora	+0,910 $\rightarrow$ +0,141 se reduce	1,00 $\rightarrow$ 1,06	sobreajuste
E2 · Parada temprana (contra el sobreajuste) iteraciones: 359 $\rightarrow$ 20, elegidas por pérdida en la validación interna	0,103 $\rightarrow$ 0,095 empeora	+0,141 $\rightarrow$ +0,080 se reduce	1,06 $\rightarrow$ 0,80	sobreajuste
E3 · Modelo más simple (contra el sobreajuste) profundidad 3 $\rightarrow$ 2; hojas 6 $\rightarrow$ 4; L2 4,25 $\rightarrow$ 10; mismas iteraciones	0,103 $\rightarrow$ 0,107 sin cambio apreciable	+0,141 $\rightarrow$ +0,087 se reduce	1,06 $\rightarrow$ 0,93	sobreajuste
E4 · Ingeniería de variables (contra el subajuste) logística híbrida con las señales de D2 (pago tardío, reserva extraordinaria, atrasos por tramos); usa sus propios hiperparámetros de la Fase 2	0,113 $\rightarrow$ 0,125 mejora	+0,026 $\rightarrow$ 0,000 se reduce	1,40 $\rightarrow$ 1,53	subajuste
E5 · Menos regularización (contra el subajuste) C: 2,75 $\rightarrow$ 27,5	0,113 $\rightarrow$ 0,113 sin cambio apreciable	+0,026 $\rightarrow$ +0,027 sin cambio apreciable	1,40 $\rightarrow$ 1,46	subajuste
E6 · Más entrenamiento (contra el subajuste) iteraciones: 359 $\rightarrow$ 718	0,103 $\rightarrow$ 0,105 sin cambio apreciable	+0,141 $\rightarrow$ +0,183 aumenta	1,06 $\rightarrow$ 0,86	sobreajuste

Tabla 2. Antes $\rightarrow$ después de cada estrategia. Las palabras «mejora» y «empeora» se refieren a la PR-AUC; el efecto sobre la brecha se juzga por su tamaño (valor absoluto).

Estrategias de mejora: antes y después

Cada flecha va del modelo de partida al modelo con la estrategia · C5 no interviene




Figura 5. Efecto de cada estrategia sobre la PR-AUC de validación, la brecha y el Lift@k por familia.

Contra el sobreajuste probamos tres estrategias. E1 muestra lo que ya había logrado la búsqueda de la Fase 2: del control sin regularizar al gradient boosting ajustado, la brecha baja de 0,910 a 0,141 y la PR-AUC en C4 sube de 0,088 a 0,103. Es la mayor reducción de brecha, aunque el modelo sigue sobreajustado.

E2 fue la sorpresa. La parada temprana, elegida por pérdida en la validación interna (C2 → C3), recortó el entrenamiento de 359 a 20 iteraciones. La brecha bajó a 0,080, pero la PR-AUC en C4 cayó a 0,095 y el Lift@k a 0,80, peor que el azar. La explicación está en la curva A: la pérdida de validación empieza a subir casi de inmediato, así que el criterio se detiene antes de que el modelo aprenda a ordenar. Aprendimos que elegir la parada por pérdida no es buena idea cuando el objetivo es ordenar familias.

E3, el modelo más simple con las mismas iteraciones, redujo la brecha a 0,087 sin cambiar la PR-AUC de forma apreciable (de 0,103 a 0,107). El Lift@k bajó de 1,06 a 0,93.

Contra el subajuste, E4 fue la única estrategia que mejoró todo a la vez: de la regresión logística a la logística híbrida la PR-AUC pasa de 0,113 a 0,125, la brecha desaparece y el Lift@k sube de 1,40 a 1,53. Hay que leerlo con cuidado. E4 cambia las variables y también los hiperparámetros, y la híbrida usa las señales de la regla D2, es decir, conocimiento del negocio y no más capacidad del modelo.

E5 no cambió nada (0,113 antes y después). Multiplicar C por diez, de 2,75 a 27,5, no tiene efecto porque el modelo ya estaba en la zona plana de la curva D. E6 la incluimos como contraprueba: duplicar las iteraciones de un modelo que ya sobreajusta dejó la PR-AUC casi igual (0,105), subió la brecha a 0,183 y bajó el Lift@k a 0,86.

Ninguna estrategia cambió el diagnóstico de su modelo.

6. Conclusiones y recomendaciones futuras

Conclusiones

- Los tres modelos de la Fase 2 tienen problemas de ajuste: el gradient boosting sobreajusta y las dos regresiones logísticas subajustan.
- Reducir el sobreajuste no mejoró la validación. Las tres estrategias cerraron parte de la brecha, pero la PR-AUC en C4 quedó entre 0,095 y 0,107. Regularizar quita lo que el modelo memorizó, pero no le agrega señal.
- La mejora que sí funcionó vino de las variables y no del modelo: la logística híbrida, que codifica las señales de la regla D2.
- Los hiperparámetros de la Fase 2 estaban bien elegidos. Las curvas de validación muestran que en los tres modelos el valor elegido está cerca del máximo.
- La decisión del proyecto no cambia. El mejor modelo llega a un Lift@k de 1,53 en C4 y la regla D2 a 1,93 con el sorteo que usamos (ver la nota posterior). C5 no intervino en este análisis.

Qué aprendimos

Antes de esta actividad leíamos el sobreajuste como un solo número, la diferencia entre entrenamiento y validación. Las curvas nos mostraron más: cuándo empieza, si la validación llega a mejorar en algún momento y si el problema es de capacidad o de señal. También aprendimos a no confiar en una sola métrica. En el gradient boosting la pérdida y la PR-AUC llevan a decisiones distintas, y la parada temprana elegida por pérdida empeoró justo lo que queríamos mejorar.

Limitaciones

- Comparamos las estrategias en C4, que ya habíamos usado para seleccionar y calibrar en la Fase 2. Una diferencia pequeña puede ser ruido.
- C4 tiene 122 eventos. Diferencias de pocas milésimas de PR-AUC no son concluyentes, y por eso solo hablamos de mejora cuando el cambio es de al menos 0,005.
- Validamos con una sola cohorte. Las tasas cambian entre ciclos (9,1 % en C2 y 6,2 % en C3), así que el resultado puede no repetirse el año siguiente.
- Los umbrales de diagnóstico son reglas prácticas y los fijamos cuando ya conocíamos los resultados de la Fase 2.
- E4 no es una comparación limpia, porque cambia las variables y también los hiperparámetros.
- La comparación con la regla D2 usa un solo sorteo entre familias con el mismo puntaje. Con otros sorteos su Lift@k en C4 va de 1,53 a 1,99, con una media de 1,75.

Recomendaciones

- Repetir este diagnóstico cada mayo, cuando se conozca el resultado del ciclo, y evaluar la logística híbrida en esa cohorte nueva.
- Si volvemos a entrenar un gradient boosting, elegir el número de iteraciones con la métrica de ordenamiento (PR-AUC o Lift@k) en la validación interna, y no con la pérdida.
- Buscar información nueva antes que modelos más complejos. El análisis de alcance encontró una que ya está en los registros: quién sigue sin pagar a mitad de campaña. Falta probarla en la próxima campaña.
- Mantener la regla D2 para priorizar mientras ningún modelo la supere en una cohorte que no haya participado en las decisiones.
- Informar el Lift@k de una regla con empates como el promedio de varios sorteos, con su mínimo y su máximo, y no con un sorteo solo.

Nota posterior: el sorteo entre familias empatadas

El 3 de octubre, al analizar por qué la lista no llega a más familias, revisamos cómo se forma la lista de la regla D2. Muchas familias tienen el mismo puntaje y el corte de la lista cae entre ellas, así que el orden entre empatadas se decide con un sorteo de semilla fija. Repetimos ese sorteo cien veces. En C4, la lista de D2 alcanza entre el 24 % y el 32 % de los casos según cómo caiga, lo que equivale a un Lift@k de 1,53 a 1,99. La media es 28 % y 1,75. Con el sorteo que usamos en la Fase 2 fue 31 % y 1,93, cerca del extremo alto.

En promedio la regla sigue por encima de la logística híbrida (1,75 frente a 1,53), pero en el extremo bajo la iguala (24 % de los casos). La ventaja de D2 sobre el mejor modelo en C4 es entonces menor y menos firme de lo que sugiere una sola cifra. Lo que sostiene la decisión es la prueba final en C5, que hicimos una sola vez en la Fase 2 y no repetimos: ahí la regla casi duplicó al azar y la logística híbrida no lo superó.

Esta nota no cambia ninguna cifra del diagnóstico, que trata de los modelos y no de la regla. El análisis completo está en docs/alcance_lista.md y en el cuaderno 06_alcance_lista.

7. Referencias técnicas

- [1] F. Pedregosa *et al.*, «Scikit-learn: Machine Learning in Python», *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.
- [2] scikit-learn developers, «Validation curves: plotting scores to evaluate models», Guía de usuario de scikit-learn. https://scikit-learn.org/stable/modules/learning_curve.html
- [3] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2.ª ed. Nueva York: Springer, 2009, cap. 7.
- [4] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016, caps. 5 y 7.
- [5] L. Prechelt, «Early Stopping — But When?», en *Neural Networks: Tricks of the Trade*, LNCS 1524. Berlín: Springer, 1998, pp. 55-69.
- [6] J. H. Friedman, «Greedy function approximation: A gradient boosting machine», *The Annals of Statistics*, vol. 29, n.º 5, pp. 1189-1232, 2001.
- [7] H. Zou y T. Hastie, «Regularization and variable selection via the elastic net», *Journal of the Royal Statistical Society: Series B*, vol. 67, n.º 2, pp. 301-320, 2005.
- [8] T. Akiba, S. Sano, T. Yanase, T. Ohta y M. Koyama, «Optuna: A Next-generation Hyperparameter Optimization Framework», en *Proc. 25th ACM SIGKDD*, 2019, pp. 2623-2631.
- [9] T. Saito y M. Rehmsmeier, «The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets», *PLoS ONE*, vol. 10, n.º 3, e0118432, 2015.

Código y resultados: github.com/ggranizo2507/prediccion-matricula-lemas
(notebooks/overfitting_analysis.ipynb, src/diagnostico.py, results/).